Hurtownie danych projekt

Problem:

Pozyskanie danych, obróbka ich, a następnie analiza w statystycznych celach

Dane:

- Głównym źródłem danych jest plik csv pobrany ze strony kaggle: https://www.kaggle.com/datasets/rohiteng/amazon-sales-dataset

- Dodatkowe źródła danych (wykonane ręcznie), to baza danych, oraz plik xml zawierające niewielką liczbę przykładów.

Cel:

1. Pozyskanie danych
2. Połączenie ich
3. Obróbka w power querry i analiza danych z pomocą power bi

Sposób wykonania:

1. Pozyskanie danych

Dane zostały wybrane ze strony kaggle. Wybrana została baza sprzedaży produktów amazon z 2025 roku. Znajduje się tam około 100 tysięcy unikalnych rekordów sprzedaży, z dokładnymi szczegółami każdej transakcji.

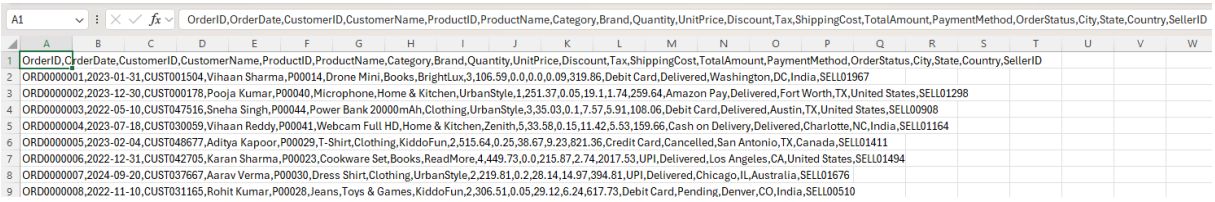

```
OrderID,OrderDate,CustomerID,CustomerName,ProductID,ProductName,Category,Brand,Quantity,UnitPrice,Discount,Tax,ShippingCost,TotalAmount,PaymentMethod,OrderStatus,City,State,Country,SellerID
ORD0000001,2023-01-31,CUST001504,Vihaan Sharma,P00014,Drone Mini,Books,BrightLux,3,106.59,0.0,0.0,0.09,319.86,Debit Card,Delivered,Washington,DC,India,SELL01967
ORD0000002,2023-12-30,CUST000178,Pooja Kumar,P00040,Microphone,Home & Kitchen,UrbanStyle,1,251.37,0.05,19.1,1.74,259.64,Amazon Pay,Delivered,Fort Worth,TX,United States,SELL01298
ORD0000003,2022-05-10,CUST047516,Sneha Singh,P00044,Power Bank 20000mAh,Clothing,UrbanStyle,3,35.03,0.1,7.57,5.91,108.06,Debit Card,Delivered,Austin,TX,United States,SELL00908
ORD0000004,2023-07-18,CUST030059,Vihaan Reddy,P00041,Webcam Full HD,Home & Kitchen,Zenith,5,33.58,0.15,11.42,5.53,159.66,Cash on Delivery,Delivered,Charlotte,NC,India,SELL01164
ORD0000005,2023-02-04,CUST048677,Aditya Kapoor,P00029,T-Shirt,Clothing,KiddoFun,2,515.64,0.25,38.67,9.23,821.36,Credit Card,Cancelled,San Antonio,TX,Canada,SELL01411
ORD0000006,2022-12-31,CUST042705,Karan Sharma,P00023,Cookware Set,Books,ReadMore,4,449.73,0.0,215.87,2.74,2017.53,UPI,Delivered,Los Angeles,CA,United States,SELL01494
ORD0000007,2024-09-20,CUST037667,Aarav Verma,P00030,Dress Shirt,Clothing,UrbanStyle,2,219.81,0.2,28.14,14.97,394.81,UPI,Delivered,Chicago,IL,Australia,SELL01676
ORD0000008,2022-11-10,CUST031165,Rohit Kumar,P00028,Jeans,Toys & Games,KiddoFun,2,306.51,0.05,29.12,6.24,617.73,Debit Card,Pending,Denver,CO,India,SELL00510
```

Po pobraniu otrzymałem plik csv zawierający powyżej przykładowe dane (łącznie 100000). Było to jedyne źródło, ale w celu urozmaicenia problemu stworzone zostały jeszcze dwa dodatkowe źródła danych.

Następnym (pobocznym) był plik xml, w którym jest jeden przykład, dosyć złożony w implementacji (wolałem go nie umieszczać, bo był bardzo długi).

Ostatnim źródłem danych jest stworzona lokalnie baza danych za pomocą SQL Server Managament Studio, która zawiera 10 przykładów. Tabela nazywa się „dbo.Orders_Sample”

Wyniki | Komunikaty

	OrderID	OrderDate	CustomerID	CustomerName	ProductID	ProductName	Category	Brand	Quantity	UnitPrice	Discount	Tax	ShippingCost	TotalAmount	PaymentMethod	OrderStatus
1	ORD0000001	2023-01-31	CUST001504	Vihaan Sharma	P00014	Drone Mini	Books	BrightLux	3	106.59	0.0	0.0	0.09	319.86	Debit Card	Delivered
2	ORD0000002	2023-12-30	CUST000178	Pooja Kumar	P00040	Microphone	Home & Kitchen	UrbanStyle	1	251.37	0.05	19.1	1.74	259.64	Amazon Pay	Delivered
3	ORD0000003	2023-05-15	CUST000921	John Doe	P00102	Smartwatch	Electronics	TechEdge	2	150.00	0.10	15.0	5.50	290.50	Credit Card	Shipped
4	ORD0000004	2023-08-20	CUST002341	Anna Kowalska	P00055	Coffee Maker	Appliances	BrewMaster	1	89.99	0.0	9.0	4.20	103.19	PayPal	Pending
5	ORD0000005	2023-02-11	CUST000442	Liam Wilson	P00022	Yoga Mat	Sports	FitLife	5	25.00	0.0	2.5	2.00	129.50	Debit Card	Delivered
6	ORD0000006	2023-10-05	CUST001188	Sato Hiroshi	P00089	Wireless Mouse	Computing	LogiTech	2	45.50	0.05	4.5	3.00	94.45	Credit Card	Delivered
7	ORD0000007	2023-03-22	CUST003005	Elena Gomez	P00210	Sunglasses	Fashion	SunBlock	1	120.00	0.20	0.0	6.00	102.00	Amazon Pay	Shipped
8	ORD0000008	2023-11-12	CUST000876	Jean Dupont	P00012	Backpack	Travel	Nomad	1	75.00	0.0	15.0	0.00	90.00	Credit Card	Delivered
9	ORD0000009	2023-06-30	CUST002551	Maria Rossi	P00333	Blender	Appliances	SmoothiePro	1	199.99	0.10	40.0	10.00	229.99	PayPal	Cancelled
10	ORD0000010	2023-09-09	CUST001002	Chen Wei	P00067	Keyboard	Computing	TypeFast	3	60.00	0.0	18.0	5.00	203.00	Debit Card	Delivered

Mamy zatem 3 źródła danych, główne zawierające dominującą liczbę danych, oraz dwa poboczne. Trzeba je teraz połączyć.

2. Połączenie danych w hurtowni danych

Mamy już dane, trzeba je teraz połączyć tak otrzymać stabliny plik zawierający wszystkie dane z nich. Dodatkowo, proces ma się aktualizować w przypadku edycji danych w dowolnym z plików. W tym celu wykorzystany został Visual studio 2022. Z wykorzystaniem narzędzia integration services zbudowana została hurtownia danych. Pierwszym etapem, było połączenie wszystkich trzech źródeł w jedno, które je poprawnie łączyło i aktualizowało. W tym celu zostały stworzone XML source, OLE DB Source, oraz Flat File Source (plik csv). Każde z tych źródeł (poza głównym) wymagało konwersji danych, aby wszystkie typy i najlepiej ich długości się zgadzały. Lookupy służyły powiązaniu kolumn z kolumną wyjściową tabeli sql, do której te dane miały trafiać. Następnie dane zostały złączone (tylko te nowe), a następnie wysłane do tabeli docelowej dbo.Orders_Import.

Tabela w SQL wygląda tak:

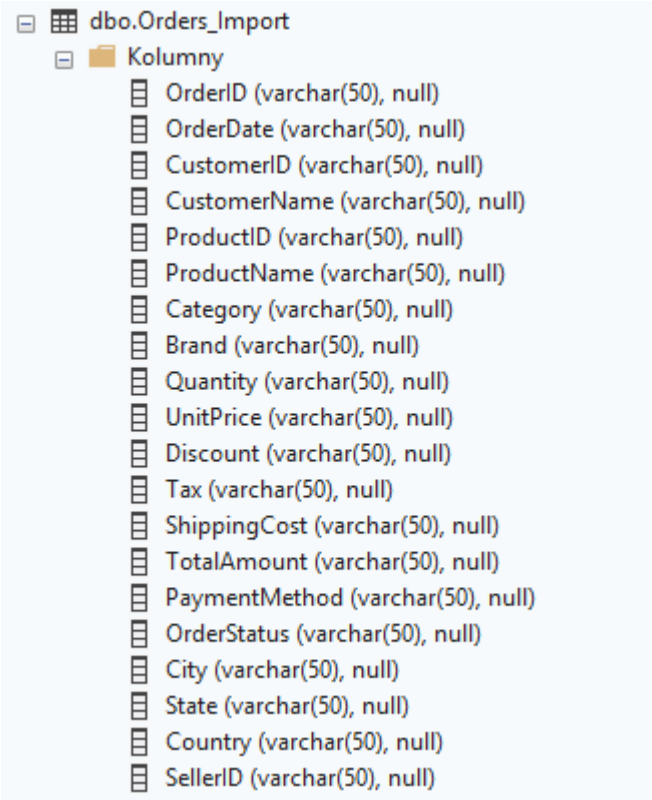

Analogicznie wyjściowa.

Ostatecznie cały schemat wygląda tak:

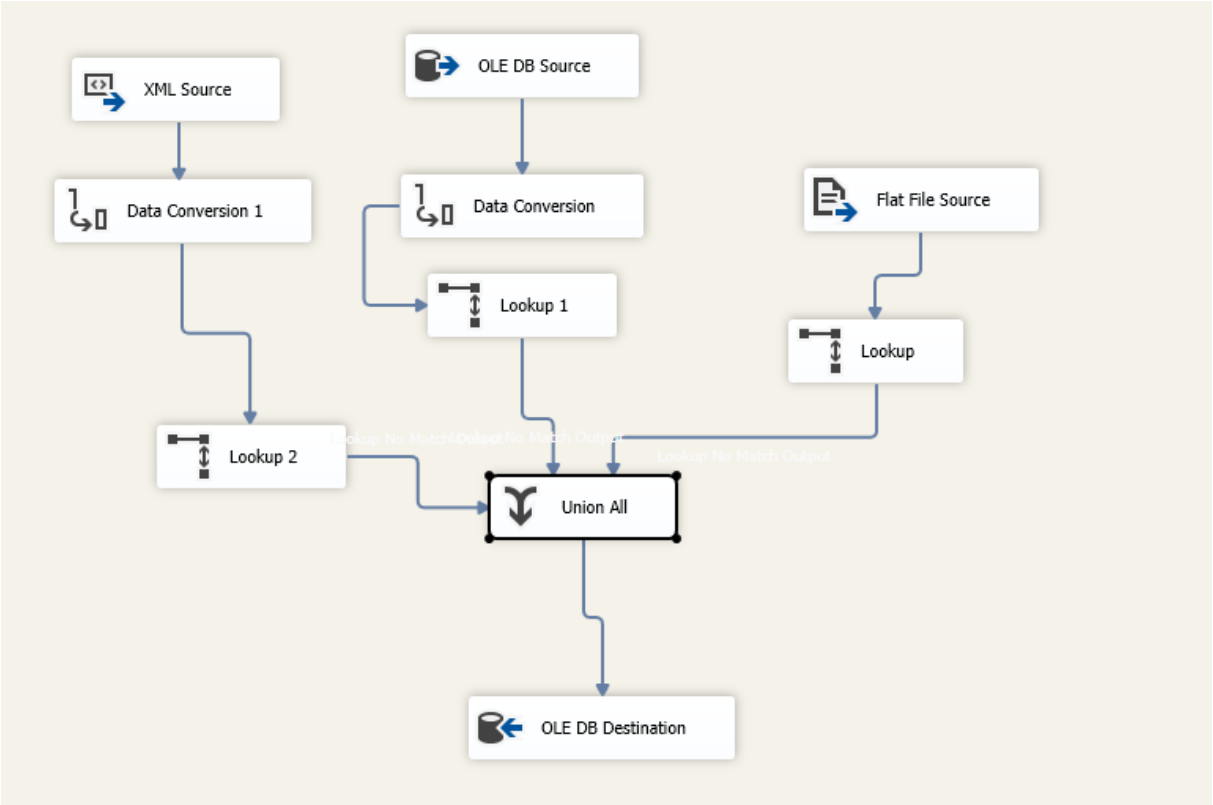

Po uruchomieniu i poprawnym zaimplementowaniu wszystkiego hurtownia uruchomiła się, zadziałała, i przekazała: 1,10,100000 danych, czyli łącznie 100011 wierszy.

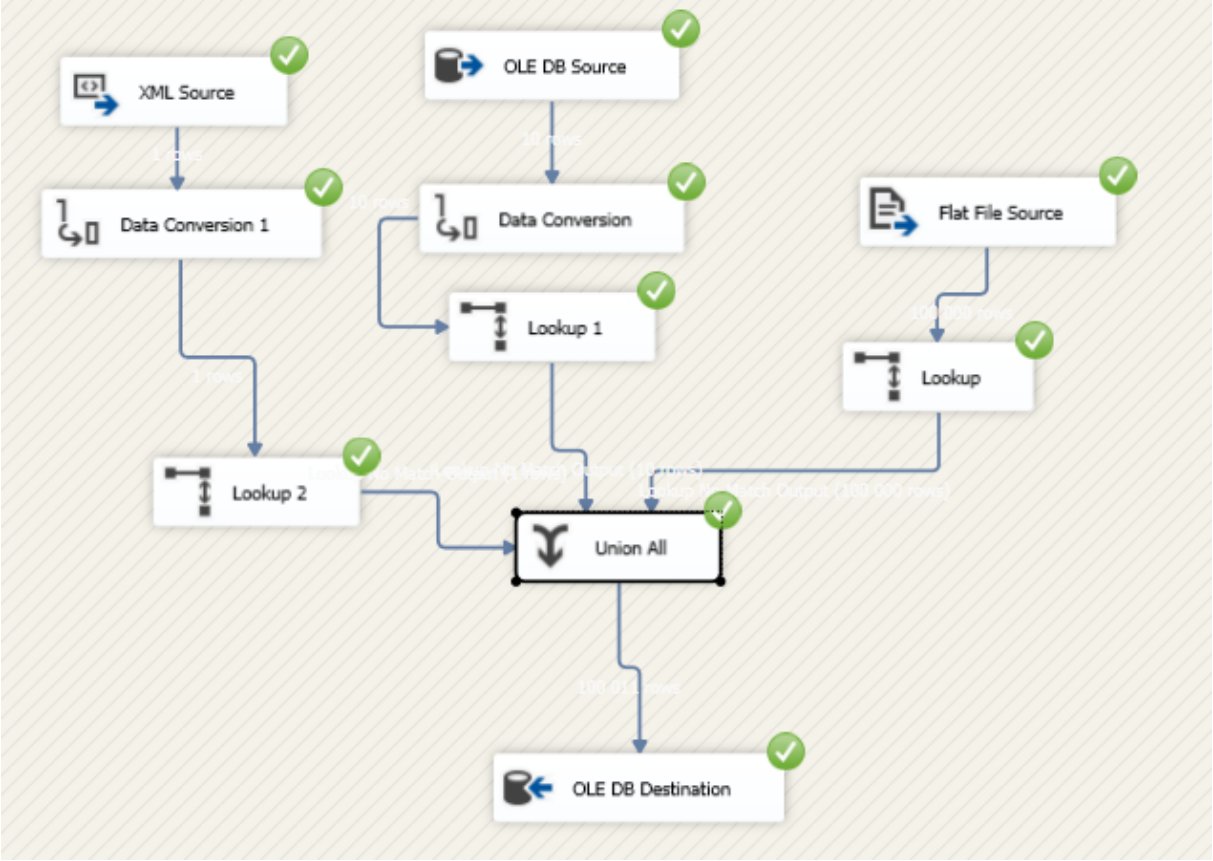

3. Power Querry + Power BI

Na wyjściu hurtowni została umieszczona baza danych. Wykorzystałem ją w excelu do uruchomienia power querry. Dane przed zaczytaniem przekształciłem, obróbki wymagały jedynie kolumny z datą oraz ilość i ceny, ponieważ wszystkie typy były ustawione na string (tekst).

Quantity	UnitPrice	Discount	Tax	ShippingCost	TotalAmount
3	106.59	0.0	0.0	0.09	319.86
1	251.37	0.05	19.1	1.74	259.64
2	150.00	0.10	15.0	5.50	290.50
1	89.99	0.0	9.0	4.20	103.19
5	25.00	0.0	2.5	2.00	129.50

Quantity	UnitPrice	Discount	Tax	ShippingCost	TotalAmount
3	106,59	0	0	0,09	319,86
1	251,37	0,05	19,1	1,74	259,64
2	150	0,1	15	5,5	290,5
1	89,99	0	9	4,2	103,19

Korzystane tu zostało narzędzie power querry, aby rodzielić tabelę na pomniejsze, a następnie utworzony model gwiazdy z podziałem na 4 tabele. Główna – tabela faktów, Product – zawierająca informacje o produkcie, Location oraz Customer analogicznie.

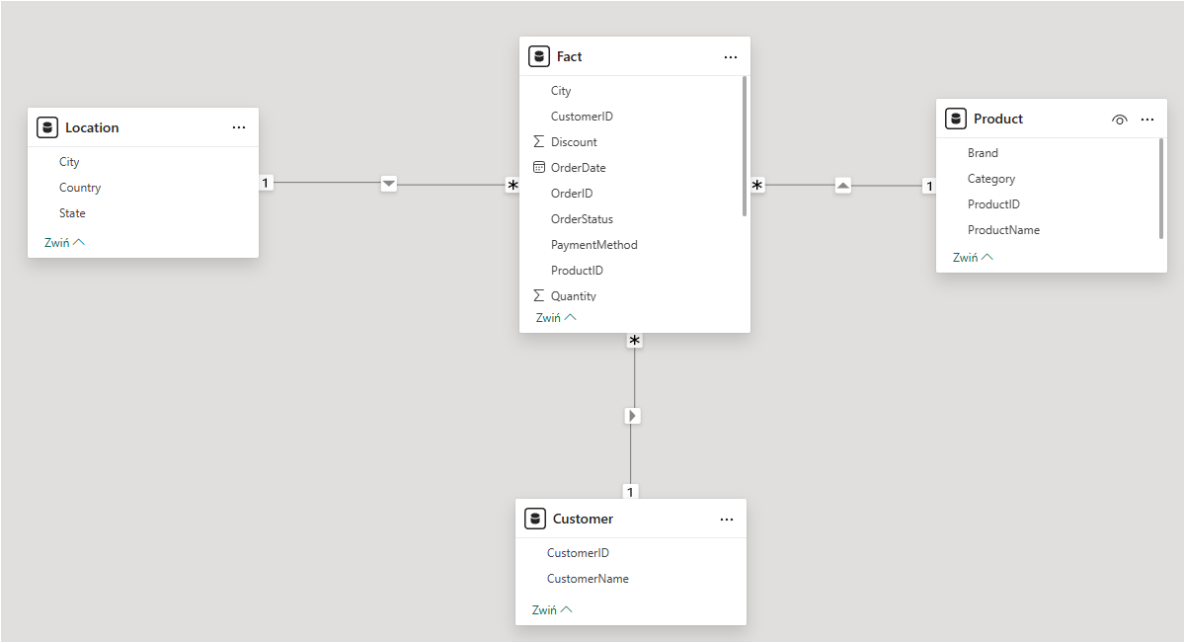

Następnie, po utworzeniu modelu gwiazdy została zastosowana hierarchia dla „category” w „product” oraz dla country w „location”. Po dodaniu odpowiednich atrybutów wygląda to tak:

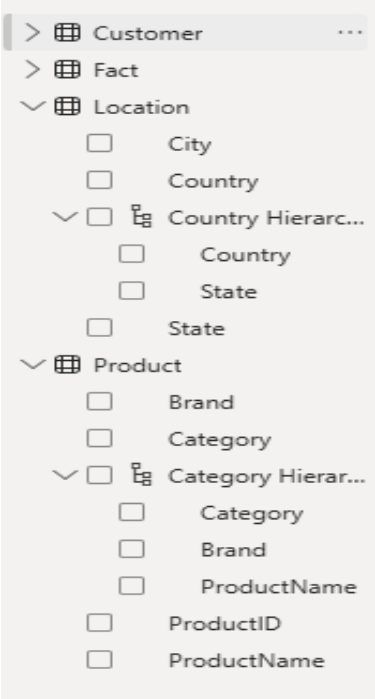

Mamy już zatem schemat relacyjnej bazy danych (schemat gwiazdy) , wraz z hierarchią. Następnym krokiem są Miary DAX. Jako najprzydatniejsze damy:

- łączna sprzedaż: S_sprzedazy = SUM('Fact'[TotalAmount])

- liczba zamówień: L_zamow = DISTINCTCOUNT('Fact'[OrderID])

(unikalne id, ponieważ jedno id mogło zawierać wiele produktów)

- średni rabat: S_przecena = AVERAGE('Fact'[Discount])

Zostały one wykorzystane do wskaźników KPI.

Wskaźniki KPI

Są to wskaźniki opisujące „postęp” względem celu, jaki ustalimy.

1. Jako jeden z celów, ustaliłem 5% średniej przeceny, względem osiąganych średnich przecen w danych okresach
2. Drugim była średnia liczba zamówień = 3, względem średniej osiąganej w danych okresach

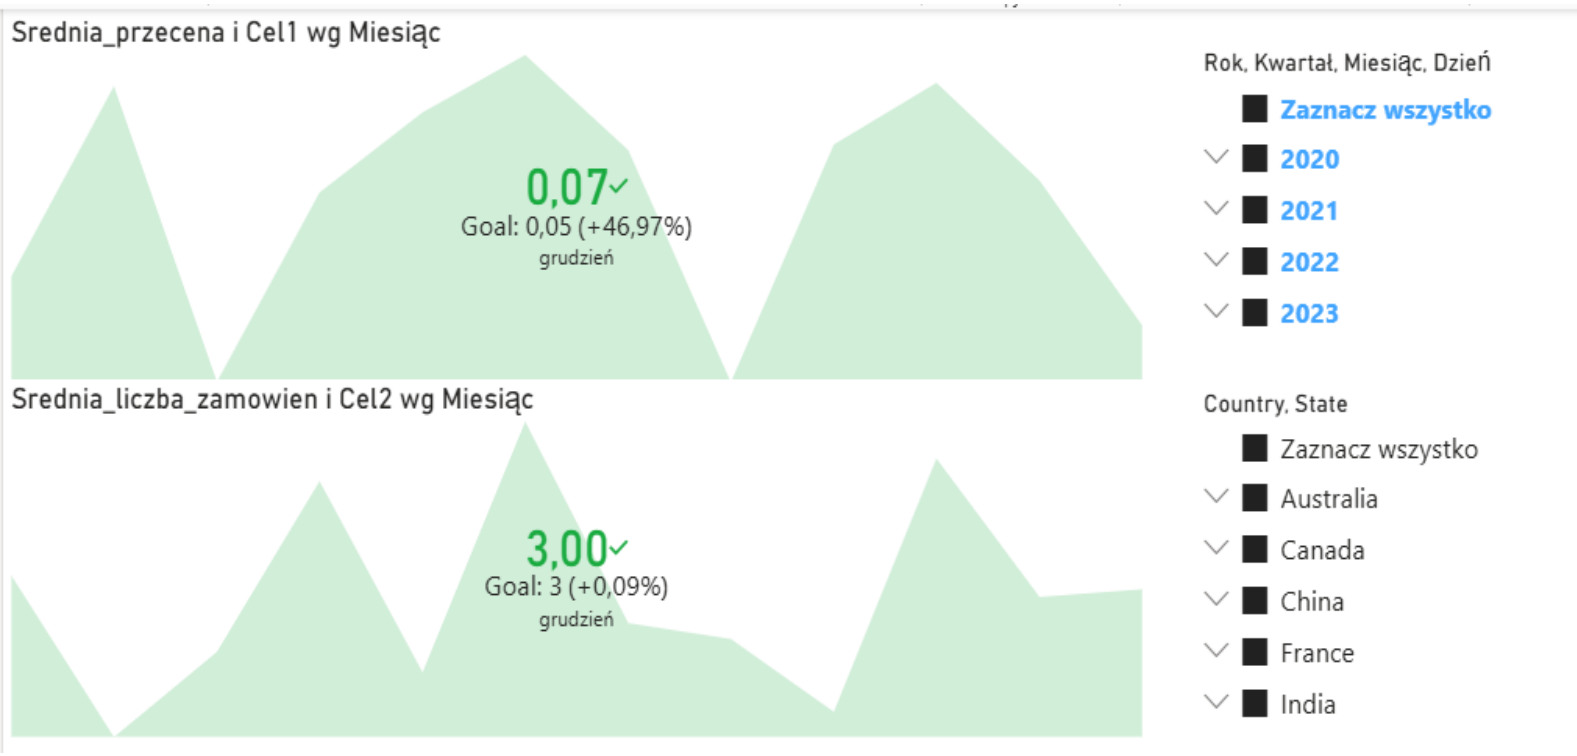

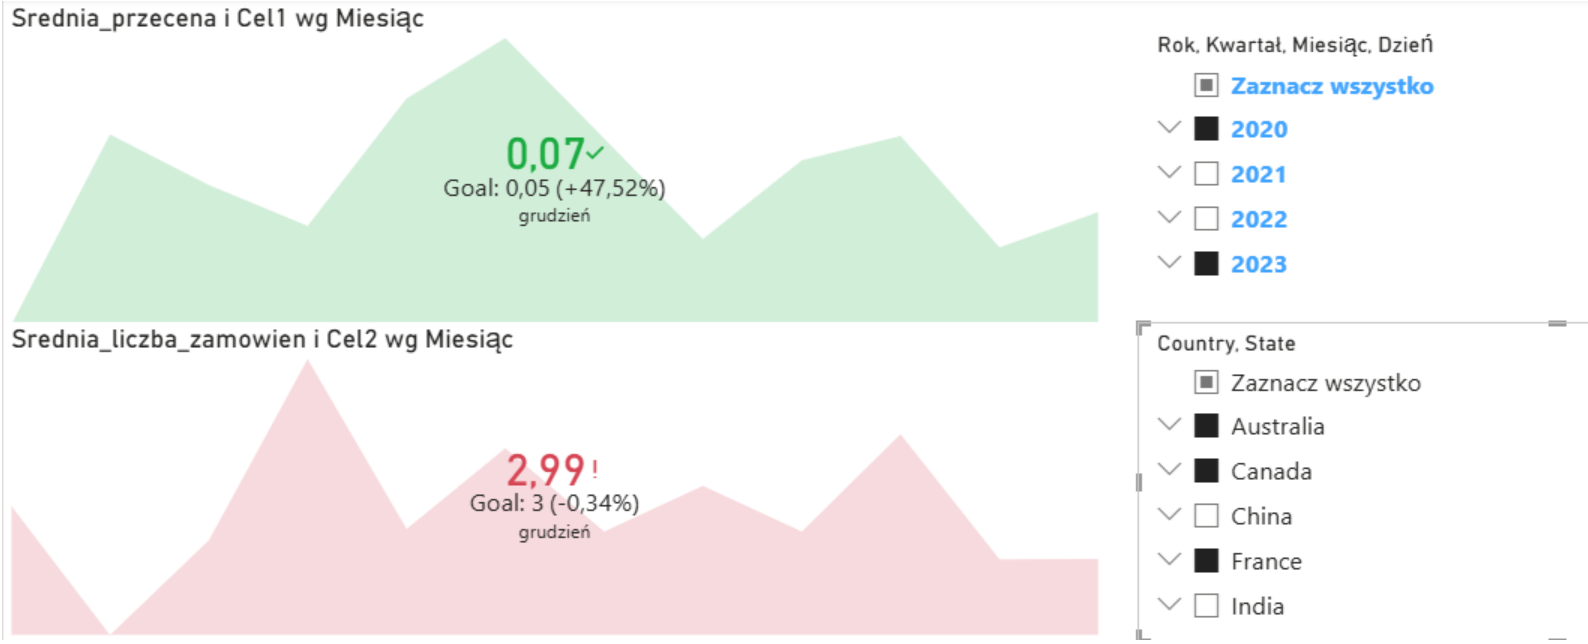

Dane zmieniają się tak jak i wykresy w zależności od wybranych krajów oraz dat (hierarchia), będących osią X (miesiące) + miary średnich (Wartości).

Dodatkowe wykresy:

Wykres zależności sumy podatków od kraju

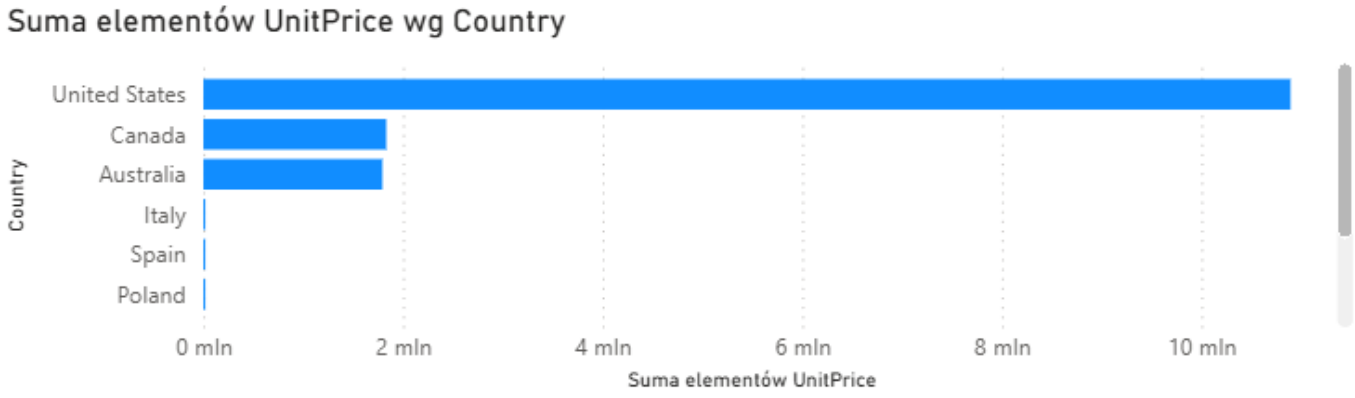

Średnia przecena w danym kraju:

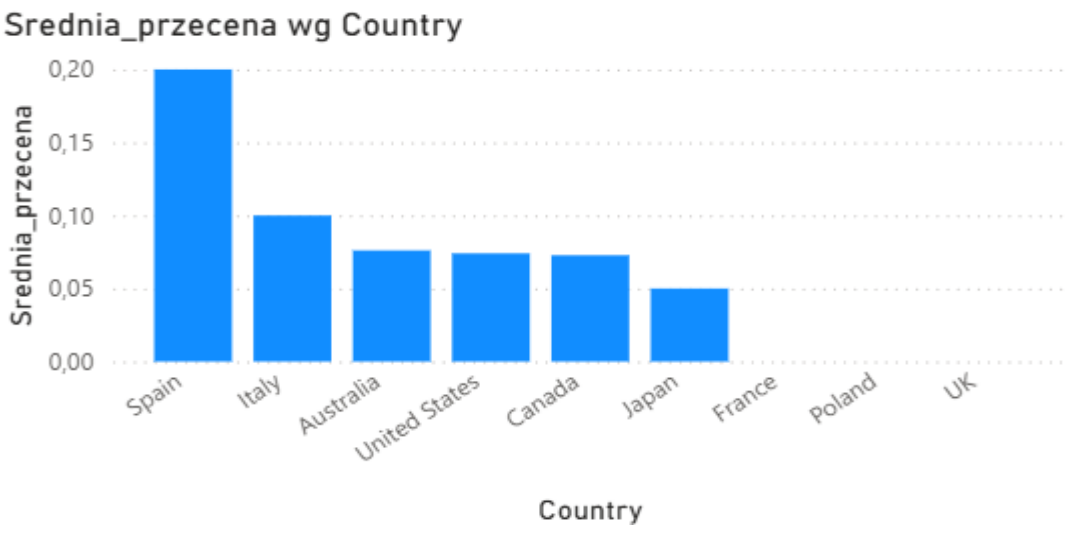

Suma sprzedaży w zależności od rodzaju płatności:

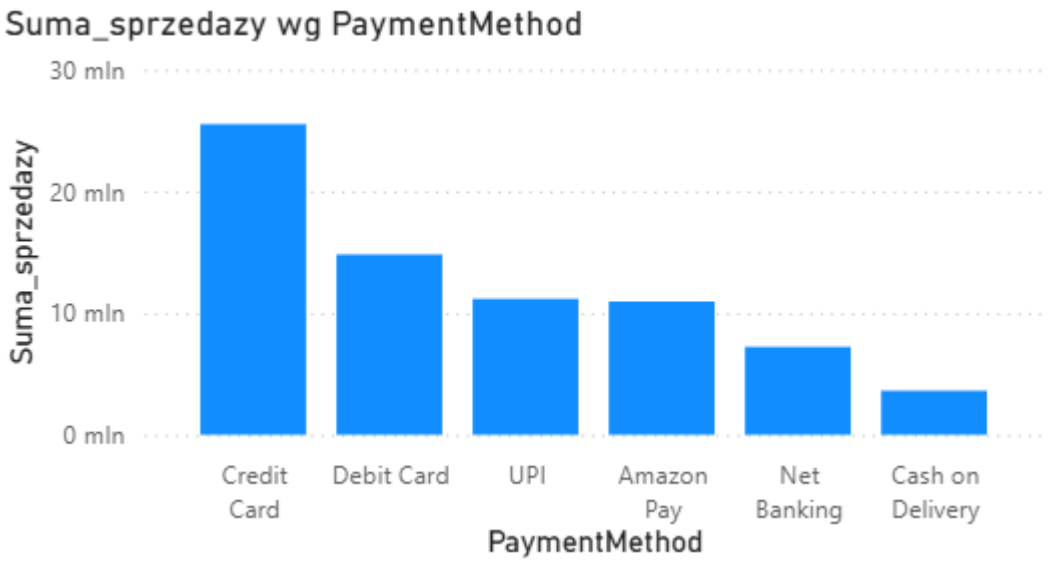

Średnia cena sprzedaży względem kraju (na mapie):
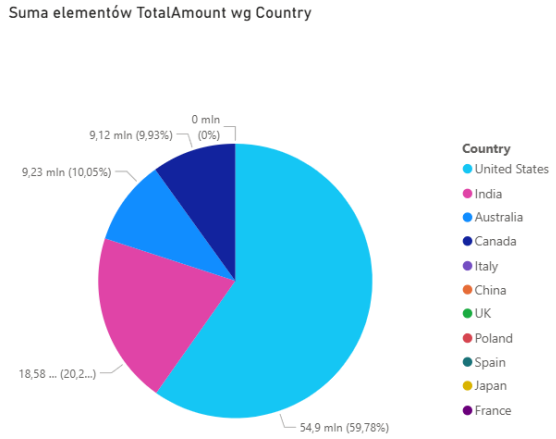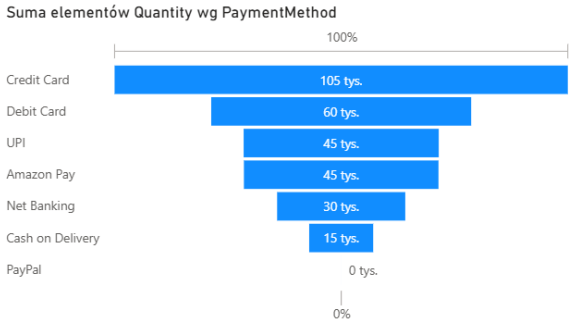
Dodatkowe wykresy: